有迹测试报告

AI+软件创新 | 团队编号 47191919 | 软件版本 0.7.0

本报告更新于2026年10月4日。已有功能基线441359e，本轮完善于2026年10月4日；下文保留2026年9月21日ca8b327工程复验及对应原始日志，并新增最新已完成验收摘要。测试结论只适用于明确列出的环境和范围，不将替身模型、虚构账号或单次成功作为真实传播效果和生产稳定性证据。

最新已完成验收与本轮待验证

本轮稳定全量回归：真实PostgreSQL临时schema参与的569项Python测试在236.570秒完成，失败0、错误0、跳过0；110项Node行为测试通过、跳过0。原始日志为evidence/current-tests.log与evidence/current-node-tests.log，摘要及指纹为evidence/current-case.json。所有前端脚本语法、pip check及local_dev doctor通过。模型回归使用替身，与下面真实调用单列。

截至441359e，真实PostgreSQL独立schema全量Python测试540项通过、0跳过；Node前端行为测试101项通过、0跳过。此计数来自docs/REAL_WORKFLOW_ACCEPTANCE_20261004.md的既有验收，不预先代表本轮代码改动后的结果。工程测试中的模型为替身，实际收费API证据另列：

已完成项	实际证据与边界
AI复盘	人工记录19阅读、5收藏、2点赞、0评论；真实调用1次、1688 Token；不证明增长
图文和视频下载	Chrome下载3张1080×1440 PNG、24秒720×960 H.264 MP4，完整解码退出0；文字图卡成片
AI读者检查	任务56651953完成三个阶段，各1次真实调用，294/584/2478 Token；非真人试读
空问题卡恢复	原任务73368e6c保留，手工作者问题恢复至待确认；仍只有原无效响应218 Token，无新增调用

本轮M185公开案例实际结果

同一官方产品资料、目标人群、使用场景和350至500字限制分别用于普通AI单次生成与系统流程。官方资料见docs/evaluation/m185_case.json；没有品牌委托，不是商业客户试点。

项目	真实记录与判定
系统任务	0102e419-26ac-445c-9366-675d6d41c7af；SUCCEEDED，第5稿，正文377字
最终确认	manual_override，用户显式人工采用；未通过有效最终AI复审，不能称全自动审核成功
系统实际用量	13次调用、24,714 Token，估算$0.0297；估算不是供应商账单
首稿成本	到首稿已累计9次调用、13,282 Token，含受众假设许可调整后的重复受众/研究，不剔除失败成本
普通AI基线	相同资料与任务单次真实调用，811 Token；基线稿不经过四Agent流程

项目	真实记录与判定
对照局限	普通AI基线生成时allow_hypothesis=False，系统后续经人工补充许可改为True；事实资料、目标和事实限制不变，但程序许可与人工干预不同，仅作探索比较
修改过程	人工保存3次：第2版仅末尾换行，第3和第5版为实际修改；第4版为AI修订，不能称零人工修改
已导出产物	准确人工采用稿、真实PNG图文ZIP、无声MP4 ZIP及分镜SRT ZIP，位于output/品牌推广完整案例
试读准备	output/品牌推广真实对照含5份实际两稿HTML及主持人记录；反馈0/5，约5位读者尚待实际执行

真实执行中，资料不足时受众假设授权曾导致继续处理，审核引用不连续触发失败恢复；最终AI复审仍在风格与措辞上循环。人工修改和显式采用才完成交付，不宣传“纯AI自动一次成功”。该单例证明流程与导出可执行。两个方法的假设许可开关和人工干预不完全相同，不能称完全同输入、严格无偏对照；不额外收费重做。它不能证明系统稿优于普通AI、成交、爆款或持续增长。

本轮已具备试读材料，尚未收集评分、满意度或提升百分比。5人阅读意见即便收集完成，也不能证明成交或长期涨粉。已生成180秒真实界面截图演示草稿并完整解码通过；它是截图演示，不是连续录屏，最终连续操作视频仍待补。公网部署继续留至最后。

一 测试对象与环境

测试对象包括backend、frontend及docs/design中的契约，覆盖创作状态机、用户身份、账号与运营、资料检索、模型调用边界、FastAPI和持久后台执行。工作区原有三个旧starter文件删除保持不变，未作为本次产品修改。

环境为Darwin 27.0.0、arm64、Python 3.12.14。依赖为FastAPI 0.141.1、Pydantic 2.13.5、LangGraph 1.2.11、PostgreSQL checkpointer 3.1.2、psycopg 3.3.6。数据库测试在实际本机PostgreSQL的临时schema中执行并清理，不用SQLite替代数据库集成结论。

二 执行方法与总体结果

```
TEST_DATABASE_URL=postgresql:///youji_operations \
PYTHONDONTWRITEBYTECODE=1 runtime/venv/bin/python \
  -m unittest discover -s tests -v
```

产品基线全量测试：169项，73.012秒，失败0、错误0、跳过0，命令退出码0。原始输出为evidence/baseline-tests.log，模块分组及环境摘要为evidence/verification.json。全量耗时是测试套件时间，不能解释为单次创作延迟或吞吐性能。

首次在受限执行环境运行时，本机数据库socket及HTTP端口被限制，出现环境连接错误。允许访问本机测试资源后完整重跑获得上述结果；没有通过跳过PostgreSQL测试获得通过结论。

测试中的模型响应由FixtureModel等替身提供；即便用例模式字段为live，也不表示访问了实际供应商。本次不产生收费模型调用，不使用真实社媒账号，不进行真实平台发布。

三 测试覆盖与判定

范围	关键检查与预期
状态与版本	拒绝非法状态、旧稿件批准及编辑后过期审核；新稿复审后可确认
身份与权限	跨用户及跨账号访问拒绝；CSRF和来源校验；密码恢复撤销旧会话
资料与来源	版本、页码与位置保留；停用排除新检索；错误引用拒绝；原快照保留
模型与费用	预算预留、路由冻结、结构错误记录、未知用量不重发
后台执行	并行分支复用、暂停继续、取消优先、旧租约提交拒绝
进程恢复	SIGKILL后新进程恢复，已提交节点及已收到响应不重复应用
运营分析	同口径历史、中位数门槛、缺失值保留、修正和撤销失效传播
API与数据迁移	实际HTTP、PostgreSQL临时schema、迁移重复/冲突/回滚及校验和

3.1 代表性恢复用例

test_sigkill_after_response_and_commit_resumes_without_duplicate_calls启动实际子进程Worker，分别在响应保存后和业务提交后终止进程。等待测试租约过期后启动新进程，检查稿件到达人工确认、阶段产物没有重复。该用例同时在SQLite与真实PostgreSQL路径执行。

test_successful_parallel_sibling_survives_other_failure让一个并行分支成功、另一个失败，恢复时检查成功分支不再调用。test_unknown_transport_does_not_repeat_paid_call验证未知传输结果阻断，而非自动再次发出付费请求。测试租约可缩短以控制用例时长，不改变生产30秒配置。

3.2 代表性证据与审核用例

test_public_material_snapshot_and_audit_survive_live_fixture_graph验证资料URL、证据快照和调用台账贯穿角色执行；其模型为测试替身。模型路由测试还检查替换审核模型返回approved但必过项失败时，后端仍拒绝。上述证明程序守卫行为，不证明模型事实理解准确。

完整用例名和每项结果可在原始测试输出中检索。所有169项均通过，未发现本次用例覆盖范围内的回归；不据此断言软件不存在其他缺陷。

四 历史真实模型与浏览器验收

4.1 真实模型试运行

仓库2026年9月20日摘要记录了“大学生整理课程资料”虚构场景。默认模型标识为deepseek-flash。首次流程在提纲阶段失败，随后修正结构提示、提纲兼容和断点续跑逻辑，续跑新增5次请求、9,210 Token，累计9次请求、17,166 Token。

结果为生成正文、审核通过、WAITING_USER，human_accepted=false，即仍等待用户最终确认。首次失败的原始响应未留存，不能重建具体字段；修复过程与摘要不能代替严格的前后对照实验。原始依据为docs/evidence/2026-09-20-outline-fix.json。

4.2 浏览器和来源记录

历史v0.6记录显示在1280×720视口完成资料检索和模拟创作，页面无整体横向溢出；真实公开搜索曾出现超时和无关结果，部分网页拒绝读取。该记录支持已观察到的操作路径，不覆盖全部移动设备、浏览器及网络环境。

历史v0.7记录在隔离测试环境中，于第3个节点保存后关闭浏览器标签页；Worker继续完成其余5个节点，重新打开显示1个稿件并等待人工确认，模型调用0。该浏览器行为本轮没有重新录制；本轮复验的是自动化套件中的实际进程恢复路径。

4.3 模拟指标的边界

衣橱演示账号的收藏率和历史中位数只是功能用例，不能作为用户真实收益。人工回填平台数据也未经平台接口独立核实。当前没有真实账号持续数周试点、用户采用率或传播增长对照结果。

五 未覆盖范围

尚未完成新版完整流程的批量真实模型质量评测、公网部署验收、并发压测、全浏览器兼容、平台OAuth和自动发布回流。尚未进行独立安全审计。现有防护和测试不能替代正式上线所需的验证。

六 后续专项评测与交付判定

6.1 AI质量对照方案

拟先建立经授权、包含不同资料完整程度和平台需求的任务集合，固定输入、模型及预算。比较单次生成与多角色流程，并拆分资料检索的贡献。评审量表包括有依据陈述比例、无依据事实数量、账号风格适配、人工修改量与最终采用情况；同时记录耗时、调用数及费用。

样本量、预算和评分人员在实验执行前确定。保留失败任务和弃用稿件，不仅展示最优输出。当前未执行该评测，因此本报告没有填入提升百分比、质量平均分或预测收益。

6.2 工程复验条件

变更模型、提示词、检索参数或协作逻辑后，重新执行相应回归并更新报告基线。真实模型评测需要独立记录模型版本和供应商用量，不能用本报告的FixtureModel结果替代。公开搜索的时效与相关性也需单独评测。

6.3 历史材料检查

本套文档新增5项针对章节覆盖、版本参数、来源文件及测试证据一致性的回归检查。加入文档检查后，全量174项测试在70.422秒内通过，失败0、错误0、跳过0；与169项产品基线结果分开记录。五份前端脚本语法检查、角色卡同步一致性、设计图册生成一致性及空白检查均通过，详见随包evidence/verification.json。

PDF交付检查包含可提取文本、页数与文件大小、团队编号、匿名信息和逐页版式。技术方案PDF低于官方10MB上限。官方网盘模板本次未成功取得，正文按官网大纲完成；最终模板封面与固定版式仍需提交前核对，此项不列为已经通过。